

IUT de Paris – Rives de Seine

Université Paris Cité

Bachelor Universitaire de Technologie
Science des Données

BUT SD S6 – Année 2025–2026

SAÉ Projet Apprentissage pour l'IA

Étude 1 : Prédiction de la qualité des vins blancs



Auteurs

Chan Sing Man Nathan
Franceschin Camille
Ratsimba Manohy

Table des matières

Introduction	2
1 Exploration des données	2
1.1 Description générale du jeu de données	2
1.2 Analyse descriptive	3
1.3 Type de problème	3
2 Préparation des données	3
2.1 Séparation entraînement / test	3
2.2 Normalisation des entrées	3
3 Construction du modèle baseline	4
3.1 Architecture du modèle	4
4 Construction des modèles avancés	4
4.1 Architecture des modèles	4
5 Analyse critique des résultats	4
5.1 Comparaison globale des modèles	4
5.2 Détection du sur-apprentissage et mise en place de l'EarlyStopping	5
6 Utilisation de l'EarlyStopping	5
6.1 Analyse des résultats avec EarlyStopping	6
7 Analyse des résultats du modèle baseline	7
7.1 Interprétation	7
Conclusion	8

Introduction

Cette étude s'inscrit dans le cadre de la SAÉ Projet *Apprentissage pour l'IA* du BUT Science des Données. Elle porte sur le jeu de données *Wine Quality* (P. Cortez et al., 2009), qui regroupe des mesures physicochimiques de vins blancs portugais (Vinho Verde) ainsi qu'une note de qualité attribuée par des dégustateurs. voir : [UCI Wine Quality](#)

L'objectif est de construire un réseau de neurones capable de **prédire la qualité d'un vin blanc** à partir de ses propriétés observées. Il s'agit donc d'un problème de **régression**. Ce rapport présente successivement l'exploration des données, leur préparation, la construction d'un modèle baseline, puis le développement et la comparaison de modèles plus avancés.

Exploration des données

1.1 Description générale du jeu de données

Le jeu de données utilisé est `winequality-white.csv`. Il contient **4 898 observations** décrivant des vins blancs, un vin étant caractérisé par **11 variables d'entrée** de nature physicochimique et **1 variable de sortie** : la note de qualité.

Les variables d'entrée sont les suivantes :

- *fixed acidity* : acidité fixe,
- *volatile acidity* : acidité volatile,
- *citric acid* : acide citrique,
- *residual sugar* : sucre résiduel,
- *chlorides* : chlorures,
- *free sulfur dioxide* : dioxyde de soufre libre,
- *total sulfur dioxide* : dioxyde de soufre total,
- *density* : densité,
- *pH*,
- *sulphates* : sulfates,
- *alcohol* : teneur en alcool.

La variable de sortie **quality** est un entier compris entre 0 et 10, représentant la qualité perçue du vin. Dans ce jeu de données, les notes observées s'étendent de 3 à 9.

1.2 Analyse descriptive




FIGURE 1 – Distribution de la variable cible **quality**

La figure 1 montre que les notes sont concentrées autour des valeurs 5, 6 et 7, ce qui signifie que les classes extrêmes (3, 4, 8, 9) sont très peu représentées. Cette distribution déséquilibrée constitue l'une des principales difficultés du problème.

1.3 Type de problème

Il s'agit d'un problème de **régression** : on cherche à prédire une valeur numérique continue (la note de qualité) à partir de variables physicochimiques.

Préparation des données

2.1 Séparation entraînement / test

Le jeu de données a été divisé de façon aléatoire en deux sous-ensembles :

- **Ensemble d'entraînement** : 80% des observations (soit environ 3 918 exemples),
- **Ensemble de test** : 20% des observations (soit environ 980 exemples).

2.2 Normalisation des entrées

Afin d'assurer une convergence stable lors de l'entraînement de nos modèles de réseaux de neurones, les variables d'entrée ont été normalisées avec **Min-Max** afin de ramener les variables entre $[0,1]$. Ajusté sur l'ensemble d'entraînement et de test.

Construction du modèle baseline

3.1 Architecture du modèle

Le modèle baseline est un Perceptron Multi-couches (MLP) simple, défini selon les spécifications suivantes :

- **Couche d'entrée** : 11 neurones (une par variable),
- **Couche cachée** : 32 neurones avec activation ReLU,
- **Couche de sortie** : 1 neurone sans fonction d'activation (régression),
- **Optimiseur** : SGD avec un taux d'apprentissage de $\eta = 0.001$,
- **Fonction de coût** : erreur quadratique moyenne (mse),
- **Métrique de suivi** : erreur absolue moyenne (mae).

Le modèle entraîné a été sauvegardé dans le fichier `baseline_model.keras`.

Construction des modèles avancés

4.1 Architecture des modèles

Les modèles avancés sont des MLP à **2 couches cachées**, entraînés avec l'optimiseur **Adam** ($\eta = 0.001$). Plusieurs variantes ont été étudiées en faisant varier :

- le **nombre de neurones** dans chaque couche cachée (ex. : 32, 64, 128),
- l'usage ou non de **couches Dropout** après les couches cachées afin de limiter le sur-apprentissage.

Les modèles entraînés ont été sauvegardés sous la forme `model_avance_XX.keras`.

Analyse critique des résultats

5.1 Comparaison globale des modèles




FIGURE 2 – Comparaison de la MAE et du LOSS pour tous les modèles testés

La figure 2 synthétise les performances de l'ensemble des modèles entraînés sur les données d'entraînements et de tests. Ce graphique compare la précision et le coût des modèles au fur-et-à-mesure des itérations de l'entraînement sur les ensembles d'entraînement (courbe en pointillé) et de test (courbe continue).

La Table 1 donne une vue récapitulative des performances des modèles sur la MAE.

TABLE 1 – Comparaison des résultats de tous les modèles

Modèle	MAE (entraînement)	MAE (test)
Baseline (1 couche, 32, SGD)	0.6228	0.6316
Avancé (2 couche : 64+32, Adam)	0.5507	1.1789
Avancé (2 couche : 32+16, Sans Dropout, Adam)	0.8144	0.6373
Avancé (2 couche : 32+16, Dropout, Adam)	0.5697	0.9107

5.2 Détection du sur-apprentissage et mise en place de l'EarlyStopping

Lors de l'analyse des courbes d'entraînement (figure 2), nous avons constaté des signes de sur-apprentissage sur certains modèles. Le cas le plus flagrant est celui du modèle `MLP_64+32_no_dropout`, dont la MAE sur l'ensemble de test augmente significativement à partir d'une trentaine d'époques, signe que le modèle commence à mémoriser les données d'entraînement, il se spécialise uniquement sur ses données d'entrée et perd sa capacité de généralisation dans ses prédictions.

Afin de pallier ce problème, nous avons mis en place de l'**EarlyStopping** dans un deuxième lancement des modèles avec une patience de 10 époques, car cela représente vingt pourcent du nombre d'époques total. Ce qui veut dire que si la fonction de coût sur l'ensemble de validation ne s'améliore pas pendant 10 époques consécutives, alors l'entraînement est interrompu. Cela permet d'éviter un entraînement inutile si stagnation, voire contre-productif comme observé sur le modèle `MLP_64+32_no_dropout`, lorsque la courbe de la l'erreur remonte.

Utilisation de l'EarlyStopping




FIGURE 3 – Comparaison de la MAE pour tous les modèles sur les données de test




FIGURE 4 – Comparaison de la LOSS pour tous les modèles sur les données de test

6.1 Analyse des résultats avec EarlyStopping

Les courbes obtenues après l'application de l'EarlyStopping mettent en évidence des comportements très différents selon les modèles, que nous allons expliquer un par un.

Le **modèle baseline** présente la convergence la plus stable et régulière : sa MAE sur le test descend progressivement pour se stabiliser autour de **0.63**, malgré son architecture simple.

Le **modèle MLP_64+32_no_dropout** présente un comportement instable tout au long de l'entraînement, c'est le modèle qui s'est arrêté le plus rapidement, car son erreur augmentait beaucoup trop autour de l'époque 15.

Le **modèle MLP_32+16_dropout** affiche quant à lui une convergence plus rapide, atteignant une MAE d'environ **0.62** autour de l'époque 10. Cependant, on observe une légère remontée de la MAE en fin d'entraînement, ce qui suggère que le Dropout, bien qu'utile pour stabiliser l'apprentissage, n'élimine pas totalement les instabilités sur ce jeu de données.

Le **modèle MLP_32+16_no_dropout** quant à lui prouve l'utilité du dropout. En utilisant les mêmes sous couches, il est égal au modèle avec dropout jusqu'à l'époque 35. Ensuite celui-ci voit sa MAE remonter comme pour l'autre modèle sans dropout ayant finalement sur-appri.

En conclusion, les quatre modèles convergent vers des performances finales très différentes. Avec le modèle baseline, qui montre que sur ce jeu de données, augmenter la complexité du modèle n'apporte pas de gain significatif. La principale valeur ajoutée de l'EarlyStopping est d'avoir évité une dégradation des performances des modèles multi sous couche sans dropout qui montrait des signes de divergence lors du lancement sur la figure 2.

Analyse des résultats du modèle baseline




FIGURE 5 – Distribution des erreurs de prédiction du modèle baseline (prédit - réel)

Les métriques obtenues sur l'ensemble de test pour le modèle baseline sont les suivantes :

TABLE 2 – Métriques du modèle baseline sur l'ensemble de test

Métrique	Valeur
Erreur Absolue Moyenne (MAE)	0.6449
Erreur Quadratique Moyenne (MSE)	0.8285
Prédictions à ± 1 note près	79.4%
Erreur maximale	4.0462

7.1 Interprétation

Afin d'évaluer plus finement les performances du modèle baseline, nous avons analysé la distribution des erreurs de prédiction, par rapport au valeur réelle :

$$\text{erreur} = \hat{y} - y$$

La distribution des erreurs (figure 5) est centrée autour de zéro, comme l'indique la ligne pointillée rouge, ce qui signifie que le modèle ne présente pas de biais systématique : il ne surestime ni ne sous-estime la qualité de manière générale.

Ainsi nous avons visualiser ces erreurs afin de nous rendre compte que la distribution suit une forme gaussienne. La majorité des erreurs sont concentrées dans l'intervalle $[-1, +1]$. Cela est confirmé par le taux de **79.4%** de prédictions correctes à ± 1 la note près.

Cependant, on observe une légère asymétrie vers la droite, avec quelques erreurs importantes pouvant atteindre **4.05 points** au maximum. Ces erreurs extrêmes concernent vraisemblablement les vins de qualité très basse ou très haute, peu représentés dans le jeu de données comme vu sur la figure 1

Conclusion

Cette étude a permis de construire et de comparer plusieurs architectures de réseaux de neurones pour la prédiction de la qualité de vins blancs. Le modèle baseline, simple mais fonctionnel, a servi de point de départ pour évaluer l'apport des modèles plus complexes.

Les modèles avancés à deux couches cachées entraînés avec Adam offrent de meilleures performances en termes de MAE. L'utilisation du Dropout permet de réduire le sur-apprentissage observé sur les modèles plus complexes.

Table des figures

1	Distribution de la variable cible <code>quality</code>	3
2	Comparaison de la MAE et du LOSS pour tous les modèles testés	4
3	Comparaison de la MAE pour tous les modèles sur les données de test	5
4	Comparaison de la LOSS pour tous les modèles sur les données de test	6
5	Distribution des erreurs de prédiction du modèle baseline (prédit - réel)	7

Liste des tableaux

1	Comparaison des résultats de tous les modèles	5
2	Métriques du modèle baseline sur l'ensemble de test	7